

# DMA Project #2

Team 22

Association Analysis  
Document Search Engine  
Document Classification

verified deliverables

Report + presentation + final zip package

## 검증된 수치만 담은 최종 발표자료

세 파트 모두 구현과 재현 검증을 끝내고, 제출 패키지로 묶는 단계입니다.

PART I

**42,921 x 1,032**

horizontal bool table; lift  $\geq 2.0$  rules 28개

PART II

**BPREF 0.278**

BM25+ scoring + stemming index

PART III

**0.725 / 0.785**

Naive Bayes / SVM accuracy

SUBMISSION

**clean zip**

AA, SE, CL, report PDF, slides PDF

## 세 과제는 조건 충족, 검증 수치, 재현성 기준으로 달았다.

### AA

Q&A question-tag 데이터를  
transaction-item 구조로 변환하고 lift  
기반 규칙을 산출

### SE

whoosh 인덱스와 BM25+ 계열  
scoring으로 검색 순위를 개선

### CL

word+char TF-IDF와 선형 모델로 4개  
저널 본문 분류

검증 완료

각 파트의 코드 산출물은 감독/검증 로그 기준 통과 상태입니다.

| 파트  | 필수 산출물                                                  | 검증 핵심값                        |
|-----|---------------------------------------------------------|-------------------------------|
| I   | part1.py, horizontal.pkl, association.pkl               | shape (42921, 1032), rules 28 |
| II  | QueryResult.py, CustomScoring.py, make_index.py, index/ | final BPREF 0.278             |
| III | clasification.py, nb.pkl, svm.pkl                       | NB 0.725, SVM 0.785           |

question을 transaction으로 고정해 42,921 x 1,032 bool matrix를 만들었다.



#### Horizontal Table

rows = questions

cols = tags


values = bool

shape (42921, 1032)

과제 조건의 transaction-item 구조를 직접 만족하므로 이후 apriori 입력이 명확해진다.

lift  $\geq 2.0$ 에서는 의미적으로 강한 태그쌍 28개만 남는다.

lift threshold별 규칙 수




제출 pkl은 과제 조건에 맞춰 lift  $\geq 2.0$ 인 28개 규칙을 저장했다.

상위 양의 연관

| 태그쌍                              | support | lift  |
|----------------------------------|---------|-------|
| anova <-> repeated-measures      | 0.0063  | 11.06 |
| arma <-> time-series             | 0.0054  | 9.49  |
| forecasting <-> time-series      | 0.0078  | 8.64  |
| svm <-> machine-learning         | 0.0065  | 6.98  |
| data-mining <-> machine-learning | 0.0055  | 5.86  |

음의 연관은 6개였고 최저 lift는 0.53으로, 강한 베타보다는 약한 주제 분리로 해석했다.

## BM25+와 stemming이 누적되어 BPREF 0.278까지 개선됐다.



## 최종 검색기는 채점 데이터 없이 범용 텍스트 통계만 사용한다.

### QueryResult

lowercase  
hyphen/slash split  
punctuation removal  
stopwords fallback  
OrGroup.factory(0.5)

### CustomScoring

BM25+ family  
 $b = 0.80$   
 $k1 = 1.45$   
 $\text{delta} = 0.75 * \text{param}$   
log qf weight

### Index

contents field uses  
StemmingAnalyzer()  
porter-style term matching  
index/ included in zip

leakage guard

relevance.txt 미참조, 특정 query/doc 예외처리 없음, document/query 통계만 사용


## 복잡도를 올린 대안은 측정상 최종본보다 약했다.

| 방법                        | 평균 BPREF      | 판정        |
|---------------------------|---------------|-----------|
| OrGroup factor 0.3~0.7 변경 | 0.2767        | 변동 없음     |
| phrase/bigram 질의          | 0.2596        | 악화, 기각    |
| 도메인 불용어 추가                | 0.2695        | 악화, 기각    |
| 단순 PRF top3+3 / top5+5    | 0.233 / 0.219 | 크게 악화, 기각 |

### 최종 채택 기준

성능 개선폭이 작거나 음수인 방법은 구현 복잡도와 재현 위험만 늘리므로 제외했다. 최종본은 BM25+ scoring + stemming index 조합으로 고정했다.

## word TF-IDF와 char\_wb n-gram을 결합해 저널별 스타일 신호를 보강했다.



fit은 train에만 적용하고, 저장 모델은 raw text를 입력받는 Pipeline 형태입니다.



## SVM이 0.785로 최종 우세하나, 네 저널의 주제 중첩이 상한을 만든다.

최종 정확도



두 모델 모두 word+char 결합이 단일 word 표현보다 안정적으로 높았다.

| 비교 구성                       | 정확도        |
|-----------------------------|------------|
| SVM word+char (C=0.3)       | 0.785      |
| SVM word-only (C=0.5~5)     | 0.74~0.75  |
| SVM word+char (C=0.5~2)     | 0.775~0.78 |
| NB word+char (alpha=0.05)   | 0.725      |
| NB word-only / ComplementNB | 0.705      |

JMLR, AnnStat, JASA, Biometrika가 모두 통계/ML 계열이라 본문 어휘가 겹친다.

최종 제출물은 필요한 파일만 남기고 재현 가능한 형태로 묶는다.

| 경로   | 포함 파일                                                   |
|------|---------------------------------------------------------|
| AA/  | part1.py, horizontal.pkl, association.pkl               |
| SE/  | QueryResult.py, CustomScoring.py, make_index.py, index/ |
| CL/  | clasification.py, nb.pkl, svm.pkl                       |
| root | 보고서.pdf, 발표자료.pdf                                       |

#### 재현 환경

Python 3.10/3.11 권장  
Whoosh==2.7.4 고정  
nltk stopwords corpus 필요  
index/는 동일 analyzer 기준으로 제출

#### 제외 파일

COLLAB\_BOARD.md  
PART\*\_SPEC.md  
보고서 draft.md  
analysis txt/csv  
원본 과제 PDF

최종 파일명

**DMA\_project2\_team22.zip**